

— FINE-TUNING OPEN CLASS

大模型微调技术

从 SFT、Prompt Tuning、LoRA 到强化学习对齐，理解后训练如何把通用模型变成可靠的任务专家。

Presenter: 王显宗 2026 年 6 月 3 日 90-120 分钟

COURSE MAP

本课的四条主线

基础必做

SFT

用指令-回答对训练模型，让它学会遵循任务、格式和表达风格。

轻量切换

Prompt Tuning

冻结模型主体，只学习连续软提示向量，适合多任务快速切换。

工业主流

LoRA / QLoRA


在权重矩阵内注入低秩适配器，以很低成本获得接近全量微调效果。

推理增强

RL / DPO / GRPO

用偏好或可验证奖励优化策略，让模型不只模仿，还能探索更优解。

大模型的基本结构：Transformer



Encoder (编码器)

通过多头自注意力 + 前馈网络，将输入序列编码为上下文感知的隐藏表示。

Decoder (解码器)

自回归生成输出，通过 Masked Self-Attention + Cross-Attention 逐步预测下一个 token。

核心组件

Multi-Head Attention、Layer Norm、残差连接、Feed-Forward Network (FFN) —— 这些组件堆叠 N 层构成了现代大模型的骨架。

PROBLEM INTRODUCTION

一个真实问题：大模型“不听话”

请提取信息并仅输出 JSON: {"name": "...", "age": "...}

使用 Python 实现快速排序，不要解释，只输出代码。

好的，我为您提取了信息。姓名是张三，年龄是 25 岁。以下是 JSON: {"name": "张三", "age": 25} 希望对您有帮助！

快速排序是一种常用排序算法。它的基本思想是通过一趟排序将数据分隔成两部分...

模型有能力，但行为没有被约束到“你真正需要的输出形态”。微调解决的正是这种能力到行为之间的落差。

为什么会这样？

01

知识泛而不精

预训练来自海量通用文本，覆盖广，但在法律、医疗、金融等垂直领域缺少精准任务经验。

02

格式不受控

预训练目标是下一个 token 预测，天然偏向自然语言续写，而不是严格 JSON、代码或 Schema。

03

偏好未对齐

互联网文本不是高质量指令数据，模型学到的是统计相关性，不等同于安全、有用、听指令。

DEFINITION

什么是微调？

微调是在预训练模型基础上，用少量高质量、特定任务或领域数据继续训练，使模型适配下游任务的过程。

少量高质量数据

通常是几千到数百万条精心构造样本，质量远比数量更关键。



特定任务目标

学习指令遵循、输出格式、领域语气、工具使用或偏好排序。



改变行为而非结构

基础模型架构保持不变，重点调整参数或适配器带来的行为模式。

ADAPTATION OPTIONS

Prompt、RAG、微调：什么时候用谁？

效果上限

Prompt 工程
低成本 / 低上限

RAG
事实知识增强

微调
行为深度改变

全量微调
最高上限 / 高成本

成本 / 工程复杂度

如果问题是“缺资料”，优先 RAG；如果问题是“行为模式不稳定”，微调更合适；如果只是简单任务，Prompt 工程常常足够。

Part 1

SFT 监督微调

最基础、最稳定、最常见的后训练起点：让模型模仿高质量标准答案。

SFT 是什么?

输入: Instruction

明确的任务描述或问题，例如“请用 Python 实现快速排序”。

本质: Imitation Learning

模型观察标准答案，学习表达风格、逻辑结构和回复格式。

目标: Response

人类认可的高质量回复，是模型学习的金标准。

$$L_{\text{SFT}} = -1/N \cdot \sum \log P_{\theta}(y_i | x, y_{<i})$$

SFT 仍然使用语言模型的下一个 token 预测目标，只是训练样本变成了高质量指令数据。

一个具体的 SFT 样本

USER / Instruction

请用 Python 实现一个快速排序算法。

ASSISTANT / Response

```
def quick_sort(arr):  
    if len(arr) <= 1:  
        return arr  
    pivot = arr[len(arr) // 2]  
    left = [x for x in arr if x < pivot]  
    mid = [x for x in arr if x == pivot]  
    right = [x for x in arr if x > pivot]  
    return quick_sort(left) + mid + quick_sort(right)
```

训练后，模型学到“实现代码”这类指令通常应直接返回代码，而不是先输出长篇算法解释。

SFT 数据格式：和推理模板一致

```
<|system|>你是一个有帮助的编程助手。<|end|>
<|user|>用 Python 写一个快速排序。<|end|>
<|assistant|>def quicksort(arr):
    if len(arr) <= 1:
        return arr
    ...
<|end|>
```

Mask 策略

通常只在 Assistant 回复部分计算损失。

格式一致

训练模板必须与推理时的 Chat Template 对齐。

质量优先

几千条高质量样本往往胜过大量低质量样本。

SFT 的 “冰山理论”



水面以上：看得见的行为

学习 JSON、Markdown、代码块等输出格式；学习语气、详略程度和角色扮演方式。

水面以下：激活已有知识

SFT 主要不是注入全新知识，而是让模型在正确语境中调用预训练阶段已经学到的知识。

SFT 的优势与局限

优势

- 简单直接：指令-回答对即可训练。
- 效果稳定：对格式、风格、任务遵循控制力强。
- 工程成熟：TRL、Deepspeed、LLaMA-Factory 等工具链完善。

局限

- 高度依赖数据质量，Garbage In, Garbage Out。
- 容易过拟合，通常 1-3 个 epoch 即可。
- 本质是模仿，难以超越标注数据的能力上界。

Part 2

Prompt Tuning 提示微调

把人工写提示词，升级为可学习的连续向量。

— SOFT PROMPT

从离散提示到连续提示

传统 Prompt

“请按 JSON 格式输出：”
离散 token，靠人工试错。



Soft Prompt

[P1, P2, P3, Input Tokens]
连续向量，通过梯度下降自动优化。



Frozen LLM

模型主体参数冻结。
只训练少量提示向量。

核心价值：用极少参数在高维嵌入空间中搜索更有效的任务表示。

三种主流软提示方法

方法	插入位置	特点	适用场景
Prompt Tuning	输入 Embedding 层	最轻量，仅拼接可学习向量	10B+ 大模型、多任务切换
Prefix Tuning	每层 Key / Value 前缀	直接影响 Attention KV 缓存	长文本生成、摘要任务
P-Tuning v2	每层输入端	深层 Prompt Tuning，表达力更强	结构化理解、NER、关系抽取


Prompt Tuning = 冻结大模型 + 训练很小的任务向量

架构对比：插入位置决定控制力

三种提示微调方法对比

Prefix Tuning

在每层 K/V 前拼接前缀



Prompt Tuning

仅在输入层拼接



P-Tuning v2

在每层输入端拼接



多任务切换：提示微调的杀手锏

Shared

基础模型

7B / 13B 模型只加载一份到 GPU。

Task A

翻译 Prompt

KB-MB 级向量文件。

Task B

摘要 Prompt

热切换，无需换模型。

Task C

分类 Prompt

多任务服务成本很低。

Output

任务输出

由软提示引导生成或分类。

局限同样清晰：小模型效果差、收敛较慢、表达能力通常弱于 LoRA。

Part 3

LoRA

低秩适配

低成本微调的工业标准：只训练两个小矩阵，却能修正模型内部权重变化方向。

为什么需要 LoRA?

显存需求爆炸

全量微调不仅要存权重，还要存梯度和优化器状态，13B 模型常需 50GB+ 显存。

任务副本昂贵

每个任务保存一份完整模型，存储与部署成本不可持续。

多数变化低维

适配任务时真正需要改变的方向很少，可以用低秩矩阵近似权重更新。

LoRA 的核心假设：权重更新 ΔW 具有低本征秩，可以分解成两个小矩阵的乘积。

核心数学: $W = W_0 + BA$

$$h = W_0x + (\alpha / r) \cdot BAx$$

$W_0^{d \times d}$
冻结

+

$B^{d \times r}$
可训练

$A^{r \times d}$
可训练

$r \ll d$

常用 $r=4, 8, 16, 32$ 。

参数骤降

从 $d \times d$ 变为约 $2 \times d \times r$ 。

训练稳定

常见初始化: A 随机, B 为 0, 初始 $\Delta W=0$ 。

训练阶段与推理阶段

Training

冻结 W_0 ，只训练 A/B

- 显存开销低，训练状态更稳定。
- 不破坏原模型的基础表达能力。
- 可为不同任务保存不同适配器。

Inference

合并权重，零额外延迟

- $W = W_0 + (\alpha/r)BA$ 。
- merge_and_unload 后等价于普通模型推理。
- 这是 LoRA 相对 Adapter 的重要优势。

QLORA

QLoRA：把显存再压下去

NF4 量化

4-bit NormalFloat 利用权重近似正态分布的特性，降低量化损失。

双重量化

对量化常数本身再量化，每参数额外节省约 0.4 bit。

分页优化器

显存峰值溢出时把优化器状态迁移到 CPU 内存，降低 OOM 风险。

QLoRA = 4-bit 量化基础模型 + LoRA 适配器训练

实践上，QLoRA 让 RTX 3090/4090 等消费级 GPU 跑通 7B-13B 模型微调成为现实。

实践配置：从可靠默认值开始

配置项	推荐起点	说明
rank r	8 或 16	r 越大表达力越强，但参数和显存增加。
alpha	2r	常见 alpha/r 约为 2，作为更新强度缩放。
target modules	q_proj + v_proj	最小配置；标准配置可加 o_proj、gate_proj。
dropout	0.05	小数据集上有助于缓解过拟合。
学习率	1e-4 到 2e-4	LoRA 常可使用高于全量 SFT 的学习率。

Part 4

RL Alignment 强化学习对齐

从“模仿答案”走向“优化策略”：偏好对齐与可验证奖励让模型探索更好的回答。

为什么 SFT 之后还需要 RL?

SFT 的根本局限

- 被动模仿人类示例，不理解目标函数。
- 无法稳定超越标注者水平。
- 缺少探索机制，难以发现更优解法。

RL 的引入价值

- 通过尝试-反馈循环优化策略。
- 用奖励表达安全性、有用性、客观性等偏好。
- 数学与代码任务可用验证器提供自动奖励。

SFT 是“学老师怎么做”；RL 是“自己试，做对了就强化”。

LLM 里的强化学习概念

RL 概念	符号	在大模型中的对应
状态 State	s_t	Prompt + 已生成 token 序列
动作 Action	a_t	选择下一个 token
策略 Policy	$\pi_{\theta}(a s)$	LLM 输出的概率分布
奖励 Reward	r	奖励模型打分、人工偏好、单元测试或答案校验
价值 Value	$V(s)$	当前状态未来回报的估计

RLHF: ChatGPT 时代的经典三阶段

Stage 1

SFT

指令 + 人类编写标准答案，得到初始策略模型。

Stage 2

Reward Model

同一 prompt 的多个回复排序，学习人类偏好分数。

Stage 3

PPO

模型生成答案，奖励模型反馈，用策略梯度更新。


瓶颈：需同时维护 Policy、Reference、Reward、Value 等模型，显存开销大，PPO 对超参数敏感。

PPO STRUCTURE

PPO：带 KL 约束的在线策略优化



PPO 示意图



DPO: 直接偏好优化



去掉显式 RL

不再单独训练 Reward Model，也不跑 PPO 在线采样。

直接吃偏好对


训练数据就是 chosen / rejected，目标是扩大两者的 log-prob 差距。

稳定、便宜、易复现

工程复杂度接近 SFT，是离线偏好对齐的常用默认方案。

增大好回答概率，降低坏回答概率，同时约束不要偏离参考模型太远。

DPO 示意图




GRPO: 推理 RL 的关键路径



GRPO / RLVR 的价值在于：奖励可以由验证器自动给出，模型能在没有人工推理轨迹标注的情况下发展出反思、验证和长链推理行为。

GRPO 示意图



对齐与推理方法对比

方法	奖励来源	需奖励模型	需 Critic	核心场景
RLHF + PPO	人类偏好训练出的 RM	是	是	通用对话、安全与风格
DPO	偏好对中的隐式奖励	否	否	离线偏好对齐，稳定易训
GRPO	可验证规则 / 函数	否	否	数学、代码、逻辑推理
DAPO / RLVR	可验证奖励 + 长链优化	否	否	2025-2026 推理增强范式

SUMMARY

四类技术的核心定位

SFT

激活已有知识，学习指令遵循与特定格式，是高级方法的起点。

Prompt Tuning

参数极少，多任务切换成本低，但表达能力通常弱于 LoRA。

LoRA / QLoRA

工业标准的参数高效微调，兼顾成本、效果和部署便利。

DPO / GRPO / RLVR

从偏好对齐到推理增强，用奖励信号推动模型超越模仿。

推荐管线：SFT → DPO / SimPO → GRPO / DAPO + 可验证奖励

给学生的实践路线

1-2 周入门

跑通 QLoRA SFT

跑通 LLaMA-Factory + Alpaca 或领域数据集，对比微调前后的指令遵循和格式稳定性。

深入理解

做消融实验

对比 $r=4/8/16/32$ 、不同 target modules 和数据质量对效果的影响。

进阶方向

DPO 与 GRPO

用偏好数据做 DPO；在数学或代码任务中尝试可验证奖励训练。

工具推荐：LLaMA-Factory、Unsloth、HuggingFace PEFT、HuggingFace TRL。

—— Q & A

Q & A

微调不是“让模型记住更多”，而是让模型更可靠地把已有能力用在正确的任务行为上。

Presenter: 王显宗 2026 年 6 月 3 日